

Вероятностные модели причинно-следственных связей в сходящихся отображениях

Mark Ikonnikov, Vadim Strijov

23 мая 2026 г.

1 Abstract

На сегодняшний день работа с мультимодальными данными набирает всё большую популярность: учет взаимосвязей между ними улучшает качество предсказания. В статье мы предлагаем новую формулировку причинно-следственных связей применительно к методу сходящихся отображений. Дополнительно мы обсуждаем связь ССА с механизмами внимания и показываем, что attention-подобные конструкции, как и классический ССА, аппроксимируют ассоциативную структуру данных, но не идентифицируют каузальный эффект. Предложенная формулировка закладывает основу для интеграции причинного вывода в методы мультимодального представления, включая динамические системы и текстовые данные.

keywords : ССА, ССМ, Attention, CI.

2 Introduction

Современные системы анализа данных всё чаще работают с несколькими разнородными источниками информации, формируя мультимодальные представления, объединяющие текст, изображения, временные ряды и сенсорные данные. Такие постановки возникают в задачах здравоохранения, робототехники, аффективных вычислений и анализа сложных динамических систем [?]. Эффективная интеграция модальностей требует методов, способных выявлять согласованную структуру между различными представлениями данных.

Одним из классических инструментов мультимодального анализа является канонический корреляционный анализ (ССА) [?], предназначенный для поиска линейных проекций двух наборов переменных, максимизирующих корреляцию в общем латентном пространстве. ССА и его обобщения — kernel ССА, deep ССА и probabilistic ССА — широко применяются в задачах сопоставления модальностей и кросс-модального обучения [? ?]. Однако фундаментальным ограничением этих методов является их ассоциативная природа: максимизация корреляции не различает прямые причинные эффекты и зависимости, возникающие вследствие скрытых общих факторов.

С другой стороны, в анализе динамических систем были предложены методы, ориентированные на выявление направленных зависимостей, в частности Convergent Cross Mapping (ССМ), основанный на реконструкции аттракторов фазового пространства. ССМ способен отличать корреляции, обусловленные общей динамикой, от направленного влияния, однако не имеет явной вероятностной интерпретации и плохо масштабируется на высокоразмерные и мультимодальные данные.

ССА выявляет общую скрытую структуру между переменными и, следовательно, чувствителен к искажающим эффектам, вызванным ненаблюдаемыми общими причинами. В отличие от этого, метод ССМ (Convergent Cross Mapping) основан на реконструкции динамических аттракторов и не выявляет чисто ассоциативные зависимости, лишённые направленной динамической связи.

Параллельно с этим в последние годы ключевую роль в моделировании сложных зависимостей играют механизмы внимания (attention), лежащие в основе трансформерных архитектур. Несмотря на выразительность, attention-механизмы также основаны на ассоциативных мерах сходства и не обеспечивают каузальной интерпретации получаемых зависимостей.

В данной работе мы ставим своей целью формально связать канонический корреляционный анализ с аппаратом причинно-следственного вывода. Используя структурные причинные модели и оператор интервенции $do(X)$, мы показываем, что даже в линейно-гауссовской постановке канонические корреляции в общем случае не совпадают с каузальным эффектом. Это наблюдение мотивирует введение причинной версии probabilistic ССА, в рамках которой интервенционный эффект выражается через явный линейный оператор, независимый от скрытых конфаундеров.

3 Связь ССА - attention

3.1 ССА: Canonical-Correlation analysis - transformer

Мы продолжаем расширять область применимости ССА и представляем способ встраивания его в Attention.

Canonical Correlation Analysis (ССА) - стандартный инструмент для выявления линейных зависимостей между двумя наборами данных [?]. Пусть нам дано множество векторов $X \in \mathbb{R}^{n_1 \times m}$ и $Y \in \mathbb{R}^{n_2 \times m}$, где m - количество векторов. Задача ССА - найти такие аффинные преобразования $\mathbf{W}_x, \mathbf{W}_y$, которые максимизируют корреляцию между X, Y в новом пространстве:

$$\begin{aligned} \mathbf{W}_x^*, \mathbf{W}_y^* &= \arg \max_{\mathbf{W}_x, \mathbf{W}_y} \text{corr}(\mathbf{W}_x^\top X, \mathbf{W}_y^\top Y) \\ &= \arg \max_{\mathbf{W}_x, \mathbf{W}_y} \frac{\mathbf{W}_x^\top \hat{\mathbf{E}}[XY^\top] \mathbf{W}_y}{\sqrt{\mathbf{W}_x^\top \hat{\mathbf{E}}[XX^\top] \mathbf{W}_x \mathbf{W}_y^\top \hat{\mathbf{E}}[YY^\top] \mathbf{W}_y}} \\ &= \arg \max_{\mathbf{W}_x, \mathbf{W}_y} \frac{\mathbf{W}_x^\top C_{12} \mathbf{W}_y}{\sqrt{\mathbf{W}_x^\top C_{11} \mathbf{W}_x \mathbf{W}_y^\top C_{22} \mathbf{W}_y}}, \end{aligned} \quad (1)$$

где $\hat{\mathbf{E}}[f(\mathbf{x}, \mathbf{y})] = \frac{1}{m} \sum_{i=1}^m f(\mathbf{x}_i, \mathbf{y}_i)$, матрицы ковариации X и Y есть $C_{11} = \frac{1}{m} XX^\top \in \mathbb{R}^{n_1 \times n_1}$, $C_{22} = \frac{1}{m} YY^\top \in \mathbb{R}^{n_2 \times n_2}$, а матрица кросс-ковариации X, Y есть $C_{12} = \frac{1}{m} XY^\top \in \mathbb{R}^{n_1 \times n_2}$.

Развивая идею [?] для решения воспользуемся методом Singular Value Decomposition (SVD, Martin and Maes 1979) для $Z = C_{11}^{-1/2} C_{12} C_{22}^{-1/2}$ и получим матрицы U, S, V . Тогда

$$\begin{aligned} \mathbf{W}_x^* &= C_{11}^{-\frac{1}{2}} U = \left(\frac{1}{m} XX^\top \right)^{-\frac{1}{2}} U \\ \mathbf{W}_y^* &= C_{22}^{-\frac{1}{2}} V = \left(\frac{1}{m} YY^\top \right)^{-\frac{1}{2}} V \\ \text{corr}(\mathbf{W}_x^{\top*} X, \mathbf{W}_y^{\top*} Y) &= \text{trace}(Z^\top Z)^{\frac{1}{2}} \end{aligned} \quad (2)$$

Мы рассмотрим механизм внимания, который используется для определения важности разных частей входных данных.

Механизм самовнимания определяется следующим образом:

$$\begin{aligned} \text{attn} : \mathbb{R}^{m \times d} \times \mathbb{R}^{m \times d} \times \mathbb{R}^{m \times d} &\longrightarrow \mathbb{R}^{m \times d} \\ \text{attn}(Q, K, V) &= \varphi \left(\frac{QK^\top}{\sqrt{d}} \right) V \end{aligned} \quad (3)$$

где $Q, K, V \in \mathbb{R}^{m \times d}$ представляют собой запросы, ключи и значения соответственно, а $\varphi : \mathbb{R}^{m \times m} \longrightarrow \mathbb{R}^{m \times m}$ — нелинейная функция, применяемая по строкам (обычно softmax).

Самовнимание, применяемое к входным данным $X \in \mathbb{R}^{m \times n_1}$, вычисляется следующим образом:

$$\begin{aligned} \text{self-attn} : \mathbb{R}^{m \times n_1} &\longrightarrow \mathbb{R}^{m \times d} \\ \text{self-attn}(X) &= \text{attn}(XW_q, XW_k, XW_v) \end{aligned} \quad (4)$$

где $W_q, W_k, W_v \in \mathbb{R}^{n_1 \times d}$ — матрицы параметров.

3.2 ССА и механизм внимания

И ССА, и механизмы внимания направлены на выявление взаимосвязей между двумя наборами данных. Однако они существенно различаются по подходам и областям применения:

Аспект	Механизм внимания	Канонический корреляционный анализ (ССА)
Цель	Выявить релевантные части входных последовательностей	Получить вложения в одном скрытом пространстве + снижение размерности
Мера сходства	$A = \frac{1}{\sqrt{d}}QK^\top$ — матрица внимания	$\text{tr}(A^\top S_{12}B)$, при условии $A^\top S_{11}A = B^\top S_{22}B = I$
Цель оптимизации	Минимизация задачи-специфической функции потерь	$\max_{A,B} \text{corr}(A^\top X, B^\top Y)$

Таблица 1: Сравнение механизмов внимания и ССА

Отметим, что $A^\top S_{12} B = \frac{1}{m} A^\top X Y^\top B = \frac{1}{m} A^\top X (B^\top Y)^\top = \frac{1}{m} \hat{Q} \hat{K}^\top$. Это весьма похоже на формулу матрицы внимания $A = \frac{1}{\sqrt{d}} Q K^\top$. Особенно в случае кросс-внимания, где Q — линейное преобразование X_1 , а K — линейное преобразование X_2 .

4 Формулировка СИ через ССА

4.1 Вероятностная модель канонического корреляционного анализа

Рассмотрим две случайные величины $X \in \mathbb{R}^{n_1}$ и $Y \in \mathbb{R}^{n_2}$ с совместным распределением P_{XY} . Согласно вероятностной интерпретации канонического корреляционного анализа [?], существует латентная переменная $Z \in \mathbb{R}^k$ ($k \leq \min(n_1, n_2)$), такая что:

$$\begin{aligned} Z &\sim \mathcal{N}(0, I_k) \\ X &= AZ + \varepsilon_X, \quad \varepsilon_X \sim \mathcal{N}(0, \Psi_X) \\ Y &= BZ + \varepsilon_Y, \quad \varepsilon_Y \sim \mathcal{N}(0, \Psi_Y) \end{aligned} \quad (5)$$

где $\Psi_X \in \mathbb{R}^{n_1 \times n_1}$ и $\Psi_Y \in \mathbb{R}^{n_2 \times n_2}$ — диагональные матрицы ковариаций шумов, $A \in \mathbb{R}^{n_1 \times k}$ и $B \in \mathbb{R}^{n_2 \times k}$ — матрицы загрузок.

Теорема 4.1 (Эквивалентность вероятностного и классического ССА). Пусть (U, V) — канонические направления классического ССА. Тогда существует параметризация вероятностной модели, в которой матрицы загрузок имеют вид (A^*, B^*) в вероятностной модели ССА связаны с решениями классического ССА следующим образом:

$$A^* = C_{11}^{1/2} U \Lambda^{1/2}, \quad B^* = C_{22}^{1/2} V \Lambda^{1/2} \quad (6)$$

где U, V — левые и правые сингулярные векторы матрицы

$Z = C_{11}^{-1/2} C_{12} C_{22}^{-1/2}$, Λ — диагональная матрица сингулярных значений, $C_{11} = \text{Cov}(X)$, $C_{22} = \text{Cov}(Y)$, $C_{12} = \text{Cov}(X, Y)$.

Доказательство. Из вероятностной модели следует, что ковариационная матрица совместного распределения:

$$\Sigma = \begin{pmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{pmatrix} = \begin{pmatrix} AA^\top + \Psi_X & AB^\top \\ BA^\top & BB^\top + \Psi_Y \end{pmatrix}$$

Максимизация канонической корреляции эквивалентна решению обобщенной проблемы собственных значений:

$$C_{12}C_{22}^{-1}C_{21}u = \lambda C_{11}u$$

Подстановка выражений для ковариаций из вероятностной модели и использование спектрального разложения показывает, что оптимальные матрицы загрузок должны иметь указанную форму. Подробное доказательство эквивалентности следует из анализа максимального правдоподобия вероятностной ССА и его связи с обобщенной задачей собственных значений; см. [?]. $\square$

4.2 Структурная причинная модель с оператором $\text{do}(X)$

Введем структурную причинную модель (SCM) для системы (X, Y) , где X является потенциальной причиной Y . Предположим, что существуют скрытые общие причины Z , влияющие как на X , так и на Y .

[Структурная причинная модель для ССА] Структурная причинная модель $\mathcal{M} = \langle \mathcal{U}, \mathcal{V}, \mathcal{F}, P(\mathcal{U}) \rangle$ определяется как:

$$\begin{aligned} Z &\leftarrow U_Z, \quad U_Z \sim \mathcal{N}(0, I_k) \\ X &\leftarrow f_X(Z, U_X) = AZ + U_X, \quad U_X \sim \mathcal{N}(0, \Psi_X) \\ Y &\leftarrow f_Y(X, Z, U_Y) = CX + BZ + U_Y, \quad U_Y \sim \mathcal{N}(0, \Psi_Y) \end{aligned} \quad (7)$$

где $C \in \mathbb{R}^{n_2 \times n_1}$ — матрица прямого причинного влияния X на Y , U_X, U_Y — независимые шумовые переменные.

5 Обзор подхода

5.1 Практическая интерпретация для временных рядов и текстов

Для d -вариантных временных рядов оператор $\text{do}(X_t = x)$ интерпретируется как искусственное форсирование состояния системы X в момент времени t и наблюдение за реакцией $Y_{t+\tau}$. В контексте сходящихся отображений (Convergent Cross-Mapping) это позволяет отделить прямое причинное влияние от корреляций, обусловленных общими динамическими факторами.

Для текстовых документов интервенция $\text{do}(X = x)$ соответствует модификации эмбеддингов определенных лингвистических признаков (например, тональности или тематических маркеров) и измерению изменений в связанных документах. Скрытая переменная Z здесь представляет собой семантические концепции, общие для обоих наборов документов.

6 Общая идея и пайплайн

Цель работы — восстановить структурную каузальную модель (Structural Causal Model, SCM) между двумя высокоразмерными парными временными рядами $\mathbf{X}, \mathbf{Y} \in \mathbb{R}^d$ при наличии только наблюдательных данных $\mathcal{D} = \{((t), \mathbf{X}(t)), ((t), \mathbf{Y}(t))\}_{t=1}^T$. В отличие от стандартной задачи поиска причинно-следственного графа, мы хотим получить параметрическую SCM в латентном пространстве, поддерживающую интервенционные запросы $p(\mathbf{Y} \mid (Z = z_0))$ и автоматически разделяющую данные на латентные режимы с различной каузальной структурой.

Ключевая идея — **формализация обучаемого оператора интервенции** ($Z = z_0$) **через стохастическую политику-смесь**. Каждая компонента смеси соответствует одному режиму данных (например, фазе движения), а семплирование из неё реализует soft-интервенцию на латент Z . Режимы не размечены и выводятся моделью самостоятельно через ЕМ.

Пайплайн состоит из четырёх этапов:

1. **Предобработка.** Выбор временного лага τ^* через одно-компонентный ССА, переход к сдвинутым рядам $(X_{t-\tau^*}, Y_t)$.
2. **Сжатие в латент.** С помощью ССА находим линейное подпространство размерности k , в котором концентрируется совместный сигнал; получаем декодеры D_X, D_Y и начальное представление Z .
3. **Causal Mixture Model в латенте.** Обучаем SCM с инвариантными по режимам параметрами $\theta = (A, B, C)$ и обучаемой смесевой интервенционной политикой $\pi_\xi(Z) = \sum_e w_e(\mu_e, \Sigma_e)$. Каждая компонента смеси интерпретируется как обучаемая soft-интервенция ($Z \sim (\mu_e, \Sigma_e)$).
4. **Извлечение графа.** В латентном пространстве собираем оператор $F'_e = U'_e \Lambda'_e V_e'^T$, где Λ'_e — диагональная матрица (связи только

между парными компонентами латента). Структура графа определяется ненулевыми сингулярными значениями и их направлениями.

Обоснование выбора компонентов: байесовский ССА [1] даёт идентифицируемый линейный латент с ARD-разреженностью. Causal mixture model [2] обрабатывается стандартным ЕМ-алгоритмом [3], при этом компоненты смеси получают каузальную интерпретацию как стохастические интервенции [4]. Инвариантность θ по компонентам обеспечивает идентифицируемость структурных параметров в духе [5].

7 Постановка задачи и допущения

Пусть $\mathcal{X} = \{((t), (t))\}_{t=1}^T$ — парные временные ряды, $(t), (t) \in^d$, $d \gg k$. Работаем в следующих допущениях:

Существует низкоразмерный латент $Z \in^k$, генерирующий оба сигнала. Между сигналами есть прямой каузальный канал $X \rightarrow Y$ в латенте. Структурные механизмы линейны, шумы гауссовы. Распределение латента Z нестационарно во времени и описывается смесью из E компонент (режимов), E заранее неизвестно и ограничено $E \leq E_{\max}$. Структурные параметры $\theta = (A, B, C)$ *инвариантны* по режимам; в разных режимах меняется только распределение Z (Sparse Mechanism Shift hypothesis [6]). Лаг между X и Y конечен, $\tau^* < \infty$, и идентифицируется одно-компонентным ССА.

8 Предобработка: выбор лага

Перед причинным выводом определяем временной лаг τ^* между X и Y через старший канонический коэффициент:

$$\tau^* = \arg \max_{\tau \in \{0, 1, \dots, \tau_{\max}\}} \rho_1(t_{-\tau}, t), \quad (8)$$

где $\rho_1(\cdot, \cdot)$ — старший сингулярный коэффициент кросс-ковариационного оператора. После определения τ^* работаем с выровненными парами $(X_t, Y_t) := (t_{-\tau^*}, t)$.

9 Структурная каузальная модель в латенте

Фиксируем минимальную SCM на графе

$$G_0 = \{Z \rightarrow X, Z \rightarrow Y, X \rightarrow Y\}, \quad X, Y, Z \in^k, \quad (9)$$

со структурными уравнениями:

$$\begin{aligned} Z &\sim \pi_\xi(Z), \\ X &= AZ + \varepsilon_x, \quad \varepsilon_x \sim (0, \Sigma_x), \\ Y &= BZ + CX + \varepsilon_y, \quad \varepsilon_y \sim (0, \Sigma_y), \end{aligned} \quad (10)$$

где $A, B, C \in^{k \times k}$ — структурные параметры (инвариантные по режимам), а $\pi_\xi(Z)$ — обучаемое интервенционное распределение, описывающее режимы.

10 Обучаемая операция интервенции

10.1 Параметризация -оператора

Определяем обучаемый soft-интервенционный оператор как смесь гауссиан:

$$\pi_\xi(Z) = \sum_{e=1}^{E_{\max}} w_e \cdot (Z; \mu_e, \Sigma_e), \quad \sum_e w_e = 1, \quad w_e \geq 0, \quad (11)$$

с параметрами $\xi = \{w_e, \mu_e, \Sigma_e\}_{e=1}^{E_{\max}}$. Каждая компонента e интерпретируется как **обучаемая стохастическая интервенция**:

$${}_e(Z) \equiv (Z \sim (\mu_e, \Sigma_e)). \quad (12)$$

В пределе $\Sigma_e \rightarrow 0$ компонента вырождается в классическую атомарную интервенцию ($Z = \mu_e$).

10.2 Семплирование из -оператора

Семплирование точки из обучаемой интервенционной политики реализуется в два шага:

$$e \sim (w_1, \dots, w_{E_{\max}}), \quad Z \sim (\mu_e, \Sigma_e). \quad (13)$$

В формулировке Pearl это соответствует **рандомизированной политике интервенций** [4]. Точка с индексом e обозначает выбранный режим, который *не наблюдается* и трактуется как скрытая дискретная переменная в модели.

10.3 Интерпретация компонент как режимов

Каждая компонента смеси соответствует одному режиму данных. Режимы не размечены: они выводятся моделью через апостериорные responsibilities $r_{t,e} = p(e_t = e \mid X_t, Y_t; \theta, \xi)$ на E-шаге ЕМ-алгоритма. Число фактически активных режимов $E \leq E_{\max}$ определяется автоматически через ARD-приор на веса $\{w_e\}$.

11 Полная генеративная модель

Модель факторизуется как двухуровневая mixture с causal-структурой внутри компоненты:

$$p(X, Y, Z, e \mid \theta, \xi) = \underbrace{p(e \mid \xi)}_{(w)} \cdot \underbrace{p(Z \mid e; \xi)}_{(\mu_e, \Sigma_e)} \cdot \underbrace{p(X \mid Z; \theta)}_{(AZ, \Sigma_x)} \cdot \underbrace{p(Y \mid X, Z; \theta)}_{(BZ + CX, \Sigma_y)}. \quad (14)$$

Маргинальное правдоподобие наблюдений:

$$p(X_t, Y_t \mid \theta, \xi) = \sum_{e=1}^{E_{\max}} w_e \int p(X_t \mid Z; \theta) p(Y_t \mid X_t, Z; \theta) (Z; \mu_e, \Sigma_e) dZ. \quad (15)$$

В линейно-гауссовом случае интеграл берётся аналитически:

$$p(X_t, Y_t \mid e; \theta, \xi) = \left(\begin{bmatrix} A\mu_e \\ (B + CA)\mu_e \end{bmatrix}, \Sigma_e^{XY}(\theta, \xi) \right), \quad (16)$$

где Σ_e^{XY} — выписываемая в явном виде блочная ковариация.

12 Приоры

ARD-приоры на структурные параметры (по аналогии с байесовским ССА [1]):

$$p(A \mid \alpha^A) = \prod_{j=1}^k (A_{\cdot j} \mid 0, (\alpha_j^A)^{-1} I), \quad \alpha_j^A \sim (a_0, b_0), \quad (17)$$

аналогично для B с α^B и C с α^C . Шумовые ковариации — обратное Уишарт:

$$\Sigma_x, \Sigma_y \sim (\nu_0, S_0). \quad (18)$$

ARD-приор на веса компонент смеси:

$$w \sim (\alpha_w, \dots, \alpha_w), \quad \alpha_w \ll 1 \quad (19)$$

для автоматического определения числа активных режимов.

13 Функция потерь

Объединяем компоненты в единую функцию:

$$(\theta, \xi) = - \sum_{t=1}^T \log \sum_{e=1}^{E_{\max}} w_e \cdot p(X_t, Y_t \mid e; \theta) - \log p(\theta) - \log p(w) \quad (20)$$

с компонентами:

$$p(X_t, Y_t \mid e; \theta) = \int p(X_t \mid Z; \theta) p(Y_t \mid X_t, Z; \theta) (Z; \mu_e, \Sigma_e) dZ, \quad (21)$$

$$\begin{aligned} -\log p(\theta) = & -\log p(A \mid \alpha^A) - \log p(B \mid \alpha^B) - \log p(C \mid \alpha^C) \\ & -\log p(\Sigma_x) - \log p(\Sigma_y). \end{aligned} \quad (22)$$

Семантика слагаемых.

- Marginal interventional likelihood: оценивает наблюдательные пары через смесь обучаемых -операторов. В отличие от наивного интегрирования по фиксированному prior $p(Z)$, здесь π_ξ обучается совместно с θ , что даёт сигнал для разделения каналов $Z \rightarrow Y$ и $X \rightarrow Y$.

- ARD-приоры на A, B, C обеспечивают разреженность каузальных каналов в латенте.
- Dirichlet-приор на w контролирует число активных режимов.

Отсутствие тавтологии. θ — инвариантный по режимам объект, что создаёт *сильное общее ограничение* через все компоненты смеси. Это и есть источник идентифицируемости: одни и те же (A, B, C) должны объяснять данные при всех (μ_e, Σ_e) одновременно.

14 Алгоритм обучения: ЕМ для causal mixture

Оптимизация реализуется как ЕМ-алгоритм со стандартной структурой для смесей [2, 3], расширенной разделяемыми параметрами θ через все компоненты.

Е-шаг. Для каждой точки t вычисляем апостериор скрытых переменных:

$$r_{t,e} = \frac{w_e \cdot p(X_t, Y_t \mid e; \theta, \xi)}{\sum_{e'} w_{e'} \cdot p(X_t, Y_t \mid e'; \theta, \xi)}, \quad (23)$$

$$q(Z_t \mid X_t, Y_t, e; \theta, \xi) = (\mu_{Z|XY,e}, \Sigma_{Z|XY,e}), \quad (24)$$

где $\mu_{Z|XY,e}, \Sigma_{Z|XY,e}$ — аналитические выражения через моменты гауссиан.

М-шаг (структурные параметры θ , общие). Обновление через weighted нормальные уравнения по всем точкам и режимам с весами $r_{t,e}$:

$$\theta_{\text{new}} = \arg \max_{\theta} \sum_{t,e} r_{t,e} q(Z_t \mid X_t, Y_t, e) [\log p(X_t, Y_t, Z_t \mid e; \theta)] + \log p(\theta). \quad (25)$$

М-шаг (параметры смеси ξ). Закрытые формулы как в обычной GMM:

$$w_e \propto \sum_t r_{t,e}, \quad (26)$$

$$\mu_e = \frac{\sum_t r_{t,e} [Z_t \mid X_t, Y_t, e]}{\sum_t r_{t,e}}, \quad (27)$$

$$\Sigma_e = \frac{\sum_t r_{t,e} [(Z_t - \mu_e)(Z_t - \mu_e)^\top \mid X_t, Y_t, e]}{\sum_t r_{t,e}}. \quad (28)$$

Сопряжённые обновления. ARD-гиперпараметры $\alpha^{A,B,C}$ и IW-параметры Σ_x, Σ_y — закрытые формулы из стандартного variational Bayes [7].

Algorithm 1 EM для Causal Mixture CCA

Input: Данные $= \{(X_t, Y_t)\}_{t=1}^T$, начальное приближение (θ_0, ξ_0) , гиперпараметры $(a_0, b_0, \nu_0, S_0, \alpha_w)$, верхняя оценка $E_{\max}$.

Output: Обученные параметры $(\hat{\theta}, \hat{\xi})$, responsibilities $\{r_{t,e}\}$, число активных режимов $\hat{E}$.

Инициализация: $\mu_e^{(0)}$ через k-means на CCA-латенте, $\Sigma_e^{(0)} = I$, $w_e^{(0)} = 1/E_{\max}$

for итерация $i = 1, \dots, N$ **do**

Е-шаг: вычислить $r_{t,e}^{(i)}$ и $q(Z_t \mid X_t, Y_t, e)$ аналитически

М-шаг (θ): обновить структурные параметры через взвешенные нормальные уравнения **М-шаг (ξ):** обновить w_e, μ_e, Σ_e по закрытым формулам

Сопряжённые обновления: ARD-гиперпараметры $\alpha^{A,B,C}$ и IW-параметры Σ_x, Σ_y

Прунинг: если $w_e < \varepsilon$, удалить компоненту e

return $(\hat{\theta}, \hat{\xi})$ и $\{r_{t,e}\}$.

15 Восстановление каузального графа в латенте

После обучения параметров $\hat{\theta} = (\hat{A}, \hat{B}, \hat{C})$ и компонент смеси $\hat{\xi}$ извлекаем граф следующим образом.

15.1 Per-режимный оператор связи

Для каждого режима e маргинальный оператор связи $X \rightarrow Y$ в латенте складывается из прямого канала и канала через Z :

$$F'_e = \hat{C} + \hat{B} \cdot_e (Z, X)_e (X, X)^{-1}, \quad (29)$$

где ${}_e(\cdot, \cdot)$ — ковариация при $Z \sim (\mu_e, \Sigma_e)$. Все ковариации вычисляются аналитически из структуры (10).

15.2 Диагональное сингулярное разложение

Допущение о диагональности связи между компонентами латента (только парные связи между i -й компонентой X и i -й компонентой Y) даёт:

$$F'_e = U'_e \Lambda'_e V_e'^\top, \quad (30)$$

где $\Lambda'_e = (\lambda'_{e,1}, \dots, \lambda'_{e,k})$ — **диагональная** матрица сингулярных значений, $U'_e, V'_e \in k \times k$ — ортогональные.

15.3 Извлечение графа

Каузальный граф в латенте режима e определяется ненулевыми сингулярными значениями:

$$G_e = \{(i \rightarrow i) : \lambda'_{e,i} > \tau_{\text{thresh}}\}, \quad (31)$$

где τ_{thresh} — порог, выбираемый по ARD-разреженности. Различные режимы дают различные графы G_e , что отражает изменение каузальной структуры между фазами данных.

15.4 Перенос в исходное пространство

Параметры в исходном пространстве восстанавливаются через декодеры CCA:

$$A^{\text{obs}} = D_X \hat{A}, \quad B^{\text{obs}} = D_Y \hat{B}, \quad F_e^{\text{obs}} = D_Y F'_e D_X^+. \quad (32)$$

SVD-разложение F_e^{obs} задаёт направления каузальных каналов в d .

16 Теоретические утверждения

Теорема 16.1 (Идентифицируемость SCM в латенте при неизвестных режимах). Пусть выполнены допущения 7–7 и условия:

(C1) Линейно-гауссова параметризация модели (10).

(C2) Достаточная различимость режимов. Истинное число режимов $E^* \geq 2k + 1$ и множество $\{(\mu_e, \Sigma_e)\}_{e=1}^{E^*}$ линейно независимо в пространстве первых и вторых моментов.

(C3) Матрицы A, B имеют полный столбцовый ранг, $\Sigma_x, \Sigma_y \succ 0$.

Тогда глобальный максимум соответствует истинным параметрам (A, B, C) с точностью до перестановки и смены знака компонент латента Z и перестановки индексов режимов.

Скетч доказательства Теоремы 16.1.

1. Идентифицируемость mixture-разложения следует из [8]: семейство конечных смесей невырожденных гауссиан идентифицируемо с точностью до перестановки компонент.
2. Внутри каждой компоненты $(X, Y) \mid e$ имеет гауссово распределение с моментами, явно зависящими от $(\theta, \mu_e, \Sigma_e)$.
3. Условие (C2) обеспечивает достаточное число различных моментных уравнений (аналог auxiliary variability в [5], Thm. 1).
4. Полный ранг (C3) гарантирует невырожденность системы; ARD на C фиксирует разреженность каузальных каналов.

Теорема 16.2 (Корректность переноса SCM в исходное пространство). Пусть $\text{SCM}_{\text{latent}}$ — обученная SCM с параметрами $(\hat{A}, \hat{B}, \hat{C})$ в латенте, и D_X, D_Y — линейные декодеры в исходное пространство. Тогда индуцированная SCM в $\mathcal{d}$ с параметрами $A^{\text{obs}} = D_X \hat{A}$, $B^{\text{obs}} = D_Y \hat{B}$, $F_e^{\text{obs}} = D_Y F'_e D_X^+$ удовлетворяет

$$p^{\text{obs}}(Y \mid (X)) = p^{\text{latent}}(Y \mid (X)) \Big|_{X=D_X^+, Y=D_Y^+}. \quad (33)$$

Скетч доказательства Теоремы 16.2. Прямая подстановка в структурные уравнения и проверка коммутативности -оператора с линейным декодером [9].

Утверждение 16.3 (Сходимость к классическому -оператору). При $\Sigma_e \rightarrow 0$ компонента (μ_e, Σ_e) в (11) сходится к атомарной интервенции $\delta(Z - \mu_e)$, и становится *marginal likelihood* по семейству классических интервенций $\{(Z = \mu_e)\}_{e=1}^{E_{\max}}$.

Скетч доказательства Утверждения 16.3. В пределе $\Sigma_e \rightarrow 0$ интеграл в (11) вырождается в значение интегранда в точке μ_e , что в точности соответствует Pearl'овскому оператору подстановки $Z := \mu_e$ [10].

17 Резюме

Подход состоит из:

1. **Предобработки** — выбор лага через одно-компонентный ССА.
2. **Линейного ССА-сжатия** в латент размерности k .
3. **Causal Mixture Model в латенте** с инвариантными по режимам параметрами $\theta = (A, B, C)$ и обучаемой смесевой -политикой $\pi_\xi(Z) = \sum_e w_e(\mu_e, \Sigma_e)$.
4. **ЕМ-алгоритма** для совместной оценки (θ, ξ) и автоматической сегментации данных на режимы через responsibilities.
5. **Извлечения графа** через per-режимные операторы $F'_e = U'_e \Lambda'_e V_e'^T$ с диагональной Λ'_e .

Центральная новизна. Обучаемый оператор интервенции ($Z = z_0$) формализован как смесевая стохастическая политика, компоненты которой соответствуют ненаблюдаемым режимам данных. Никакой внешней разметки режимов не требуется; режимы выводятся как побочный продукт ЕМ-алгоритма. Идентифицируемость структурных параметров обеспечивается инвариантностью θ по компонентам смеси плюс достаточной различимостью режимов.

Связь с ССМ. Диагональная структура Λ'_e согласуется с поэлементной природой shadow-manifold cross-mapping [11]; per-режимные операторы F_e^{obs} дают естественные «слои» для применения ССМ внутри каждого режима в дальнейшем развитии работы.

Список литературы

- [1] Klami A., Virtanen S., Kaski S. Bayesian Canonical Correlation Analysis. *Journal of Machine Learning Research*, 14:965–1003, 2013.
- [2] McLachlan G., Peel D. *Finite Mixture Models*. Wiley, 2000.
- [3] Dempster A. P., Laird N. M., Rubin D. B. Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society B*, 39(1):1–38, 1977.
- [4] Correa J., Bareinboim E. A Calculus for Stochastic Interventions: Causal Effect Identification and Surrogate Experiments. *AAAI*, 2020.
- [5] Khemakhem I., Kingma D., Monti R., Hyvärinen A. Variational Autoencoders and Nonlinear ICA: A Unifying Framework. *AISTATS*, 2020.
- [6] Schölkopf B., Locatello F., Bauer S., Ke N. R., Kalchbrenner N., Goyal A., Bengio Y. Toward Causal Representation Learning. *Proceedings of the IEEE*, 109(5):612–634, 2021.
- [7] Beal M. J. *Variational Algorithms for Approximate Bayesian Inference*. PhD thesis, University College London, 2003.
- [8] Teicher H. Identifiability of finite mixtures. *Annals of Mathematical Statistics*, 34:1265–1269, 1963.
- [9] Rubenstein P., Weichwald S., Bongers S., Mooij J., Janzing D., Grosse-Wentrup M., Schölkopf B. Causal Consistency of Structural Equation Models. *UAI*, 2017.
- [10] Pearl J. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, 2nd edition, 2009.
- [11] Sugihara G., May R., Ye H., Hsieh C., Deyle E., Fogarty M., Munch S. Detecting Causality in Complex Ecosystems. *Science*, 338(6106):496–500, 2012.