

Вероятностные модели причинно-следственных связей в сходящихся отображениях

Mark Ikonnikov, Vadim Strijov

23 мая 2026 г.

1 Abstract

На сегодняшний день работа с мультимодальными данными набирает всё большую популярность: учет взаимосвязей между ними улучшает качество предсказания. В статье мы предлагаем новую формулировку причинно-следственных связей применительно к методу сходящихся отображений. Дополнительно мы обсуждаем связь ССА с механизмами внимания и показываем, что attention-подобные конструкции, как и классический ССА, аппроксимируют ассоциативную структуру данных, но не идентифицируют каузальный эффект. Предложенная формулировка закладывает основу для интеграции причинного вывода в методы мультимодального представления, включая динамические системы и текстовые данные.

keywords : ССА, ССМ, Attention, CI.

2 Introduction

Современные системы анализа данных всё чаще работают с несколькими разнородными источниками информации, формируя мультимодальные представления, объединяющие текст, изображения, временные ряды и сенсорные данные. Такие постановки возникают в задачах здравоохранения, робототехники, аффективных вычислений и анализа сложных динамических систем [?]. Эффективная интеграция модальностей требует методов, способных выявлять согласованную структуру между различными представлениями данных.

Одним из классических инструментов мультимодального анализа является канонический корреляционный анализ (ССА) [?], предназначенный для поиска линейных проекций двух наборов переменных, максимизирующих корреляцию в общем латентном пространстве. ССА и его обобщения — kernel ССА, deep ССА и probabilistic ССА — широко применяются в задачах сопоставления модальностей и кросс-модального обучения [? ?]. Однако фундаментальным ограничением этих методов является их ассоциативная природа: максимизация корреляции не различает прямые причинные эффекты и зависимости, возникающие вследствие скрытых общих факторов.

С другой стороны, в анализе динамических систем были предложены методы, ориентированные на выявление направленных зависимостей, в частности Convergent Cross Mapping (ССМ), основанный на реконструкции аттракторов фазового пространства. ССМ способен отличать корреляции, обусловленные общей динамикой, от направленного влияния, однако не имеет явной вероятностной интерпретации и плохо масштабируется на высокоразмерные и мультимодальные данные.

ССА выявляет общую скрытую структуру между переменными и, следовательно, чувствителен к искажающим эффектам, вызванным ненаблюдаемыми общими причинами. В отличие от этого, метод ССМ (Convergent Cross Mapping) основан на реконструкции динамических аттракторов и не выявляет чисто ассоциативные зависимости, лишённые направленной динамической связи.

Параллельно с этим в последние годы ключевую роль в моделировании сложных зависимостей играют механизмы внимания (attention), лежащие в основе трансформерных архитектур. Несмотря на выразительность, attention-механизмы также основаны на ассоциативных мерах сходства и не обеспечивают каузальной интерпретации получаемых зависимостей.

В данной работе мы ставим своей целью формально связать канонический корреляционный анализ с аппаратом причинно-следственного вывода. Используя структурные причинные модели и оператор интервенции $do(X)$, мы показываем, что даже в линейно-гауссовской постановке канонические корреляции в общем случае не совпадают с каузальным эффектом. Это наблюдение мотивирует введение причинной версии probabilistic ССА, в рамках которой интервенционный эффект выражается через явный линейный оператор, независимый от скрытых конфаундеров.

3 Связь ССА - attention

3.1 ССА: Canonical-Correlation analysis - transformer

Мы продолжаем расширять область применимости ССА и представляем способ встраивания его в Attention.

Canonical Correlation Analysis (ССА) - стандартный инструмент для выявления линейных зависимостей между двумя наборами данных [?]. Пусть нам дано множество векторов $X \in \mathbb{R}^{n_1 \times m}$ и $Y \in \mathbb{R}^{n_2 \times m}$, где m - количество векторов. Задача ССА - найти такие аффинные преобразования $\mathbf{W}_x, \mathbf{W}_y$, которые максимизируют корреляцию между X, Y в новом пространстве:

$$\begin{aligned} \mathbf{W}_x^*, \mathbf{W}_y^* &= \arg \max_{\mathbf{W}_x, \mathbf{W}_y} \text{corr}(\mathbf{W}_x^\top X, \mathbf{W}_y^\top Y) \\ &= \arg \max_{\mathbf{W}_x, \mathbf{W}_y} \frac{\mathbf{W}_x^\top \hat{\mathbf{E}}[XY^\top] \mathbf{W}_y}{\sqrt{\mathbf{W}_x^\top \hat{\mathbf{E}}[XX^\top] \mathbf{W}_x \mathbf{W}_y^\top \hat{\mathbf{E}}[YY^\top] \mathbf{W}_y}} \\ &= \arg \max_{\mathbf{W}_x, \mathbf{W}_y} \frac{\mathbf{W}_x^\top C_{12} \mathbf{W}_y}{\sqrt{\mathbf{W}_x^\top C_{11} \mathbf{W}_x \mathbf{W}_y^\top C_{22} \mathbf{W}_y}}, \end{aligned} \quad (1)$$

где $\hat{\mathbf{E}}[f(\mathbf{x}, \mathbf{y})] = \frac{1}{m} \sum_{i=1}^m f(\mathbf{x}_i, \mathbf{y}_i)$, матрицы ковариации X и Y есть $C_{11} = \frac{1}{m} XX^\top \in \mathbb{R}^{n_1 \times n_1}$, $C_{22} = \frac{1}{m} YY^\top \in \mathbb{R}^{n_2 \times n_2}$, а матрица кросс-ковариации X, Y есть $C_{12} = \frac{1}{m} XY^\top \in \mathbb{R}^{n_1 \times n_2}$.

Развивая идею [?] для решения воспользуемся методом Singular Value Decomposition (SVD, Martin and Maes 1979) для $Z = C_{11}^{-1/2} C_{12} C_{22}^{-1/2}$ и получим матрицы U, S, V . Тогда

$$\begin{aligned} \mathbf{W}_x^* &= C_{11}^{-\frac{1}{2}} U = \left(\frac{1}{m} XX^\top \right)^{-\frac{1}{2}} U \\ \mathbf{W}_y^* &= C_{22}^{-\frac{1}{2}} V = \left(\frac{1}{m} YY^\top \right)^{-\frac{1}{2}} V \\ \text{corr}(\mathbf{W}_x^{\top*} X, \mathbf{W}_y^{\top*} Y) &= \text{trace}(Z^\top Z)^{\frac{1}{2}} \end{aligned} \quad (2)$$

Мы рассмотрим механизм внимания, который используется для определения важности разных частей входных данных.

Механизм самовнимания определяется следующим образом:

$$\begin{aligned} \text{attn} : \mathbb{R}^{m \times d} \times \mathbb{R}^{m \times d} \times \mathbb{R}^{m \times d} &\longrightarrow \mathbb{R}^{m \times d} \\ \text{attn}(Q, K, V) &= \varphi \left(\frac{QK^\top}{\sqrt{d}} \right) V \end{aligned} \quad (3)$$

где $Q, K, V \in \mathbb{R}^{m \times d}$ представляют собой запросы, ключи и значения соответственно, а $\varphi : \mathbb{R}^{m \times m} \longrightarrow \mathbb{R}^{m \times m}$ — нелинейная функция, применяемая по строкам (обычно softmax).

Самовнимание, применяемое к входным данным $X \in \mathbb{R}^{m \times n_1}$, вычисляется следующим образом:

$$\begin{aligned} \text{self-attn} : \mathbb{R}^{m \times n_1} &\longrightarrow \mathbb{R}^{m \times d} \\ \text{self-attn}(X) &= \text{attn}(XW_q, XW_k, XW_v) \end{aligned} \quad (4)$$

где $W_q, W_k, W_v \in \mathbb{R}^{n_1 \times d}$ — матрицы параметров.

3.2 ССА и механизм внимания

И ССА, и механизмы внимания направлены на выявление взаимосвязей между двумя наборами данных. Однако они существенно различаются по подходам и областям применения:

Аспект	Механизм внимания	Канонический корреляционный анализ (ССА)
Цель	Выявить релевантные части входных последовательностей	Получить вложения в одном скрытом пространстве + снижение размерности
Мера сходства	$A = \frac{1}{\sqrt{d}}QK^\top$ — матрица внимания	$\text{tr}(A^\top S_{12}B)$, при условии $A^\top S_{11}A = B^\top S_{22}B = I$
Цель оптимизации	Минимизация задачи-специфической функции потерь	$\max_{A,B} \text{corr}(A^\top X, B^\top Y)$

Таблица 1: Сравнение механизмов внимания и ССА

Отметим, что $A^\top S_{12} B = \frac{1}{m} A^\top X Y^\top B = \frac{1}{m} A^\top X (B^\top Y)^\top = \frac{1}{m} \hat{Q} \hat{K}^\top$. Это весьма похоже на формулу матрицы внимания $A = \frac{1}{\sqrt{d}} Q K^\top$. Особенно в случае кросс-внимания, где Q — линейное преобразование X_1 , а K — линейное преобразование X_2 .

4 Формулировка СИ через ССА

4.1 Вероятностная модель канонического корреляционного анализа

Рассмотрим две случайные величины $X \in \mathbb{R}^{n_1}$ и $Y \in \mathbb{R}^{n_2}$ с совместным распределением P_{XY} . Согласно вероятностной интерпретации канонического корреляционного анализа [?], существует латентная переменная $Z \in \mathbb{R}^k$ ($k \leq \min(n_1, n_2)$), такая что:

$$\begin{aligned} Z &\sim \mathcal{N}(0, I_k) \\ X &= AZ + \varepsilon_X, \quad \varepsilon_X \sim \mathcal{N}(0, \Psi_X) \\ Y &= BZ + \varepsilon_Y, \quad \varepsilon_Y \sim \mathcal{N}(0, \Psi_Y) \end{aligned} \quad (5)$$

где $\Psi_X \in \mathbb{R}^{n_1 \times n_1}$ и $\Psi_Y \in \mathbb{R}^{n_2 \times n_2}$ — диагональные матрицы ковариаций шумов, $A \in \mathbb{R}^{n_1 \times k}$ и $B \in \mathbb{R}^{n_2 \times k}$ — матрицы загрузок.

Теорема 4.1 (Эквивалентность вероятностного и классического ССА). Пусть (U, V) — канонические направления классического ССА. Тогда существует параметризация вероятностной модели, в которой матрицы загрузок имеют вид (A^*, B^*) в вероятностной модели ССА связаны с решениями классического ССА следующим образом:

$$A^* = C_{11}^{1/2} U \Lambda^{1/2}, \quad B^* = C_{22}^{1/2} V \Lambda^{1/2} \quad (6)$$

где U, V — левые и правые сингулярные векторы матрицы

$Z = C_{11}^{-1/2} C_{12} C_{22}^{-1/2}$, Λ — диагональная матрица сингулярных значений, $C_{11} = \text{Cov}(X)$, $C_{22} = \text{Cov}(Y)$, $C_{12} = \text{Cov}(X, Y)$.

Доказательство. Из вероятностной модели следует, что ковариационная матрица совместного распределения:

$$\Sigma = \begin{pmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{pmatrix} = \begin{pmatrix} AA^\top + \Psi_X & AB^\top \\ BA^\top & BB^\top + \Psi_Y \end{pmatrix}$$

Максимизация канонической корреляции эквивалентна решению обобщенной проблемы собственных значений:

$$C_{12}C_{22}^{-1}C_{21}u = \lambda C_{11}u$$

Подстановка выражений для ковариаций из вероятностной модели и использование спектрального разложения показывает, что оптимальные матрицы загрузок должны иметь указанную форму. Подробное доказательство эквивалентности следует из анализа максимального правдоподобия вероятностной ССА и его связи с обобщенной задачей собственных значений; см. [?]. $\square$

4.2 Структурная причинная модель с оператором $\text{do}(X)$

Введем структурную причинную модель (SCM) для системы (X, Y) , где X является потенциальной причиной Y . Предположим, что существуют скрытые общие причины Z , влияющие как на X , так и на Y .

[Структурная причинная модель для ССА] Структурная причинная модель $\mathcal{M} = \langle \mathcal{U}, \mathcal{V}, \mathcal{F}, P(\mathcal{U}) \rangle$ определяется как:

$$\begin{aligned} Z &\leftarrow U_Z, \quad U_Z \sim \mathcal{N}(0, I_k) \\ X &\leftarrow f_X(Z, U_X) = AZ + U_X, \quad U_X \sim \mathcal{N}(0, \Psi_X) \\ Y &\leftarrow f_Y(X, Z, U_Y) = CX + BZ + U_Y, \quad U_Y \sim \mathcal{N}(0, \Psi_Y) \end{aligned} \quad (7)$$

где $C \in \mathbb{R}^{n_2 \times n_1}$ — матрица прямого причинного влияния X на Y , U_X, U_Y — независимые шумовые переменные.

5 Вероятностная причинная модель для сходящихся отображений

Рассматривается задача восстановления причинной структуры между двумя высокоразмерными парными временными рядами

$$= \{(X^{\text{obs}}(t), Y^{\text{obs}}(t))\}_{t=1}^T, \quad X^{\text{obs}}(t), Y^{\text{obs}}(t) \in \mathbb{R}^d, \quad d \gg 1.$$

Под восстановлением причинной структуры в данной работе понимается не построение одного бинарного графа между исходными координатами, а оценивание структурной причинной модели (SCM), которая

позволяет отвечать на интервенционные запросы вида

$$p(Y \mid (X = x)), \quad p(Y \mid (Z = z_0)).$$

Такой объект сильнее обычной корреляционной модели: он должен отделять прямой канал влияния $X \rightarrow Y$ от зависимости, вызванной общими скрытыми факторами.

Основная трудность состоит в том, что прямое построение SCM в пространстве d приводит к слишком большому числу параметров. Поэтому причинная модель строится в латентном пространстве малой размерности $k \ll d$, а затем переносится обратно в исходное пространство через линейные декодеры, полученные на этапе ССА-сжатия.

5.1 Предобработка и выбор лага

Для временных рядов сначала выбирается задержка между сигналами. Пусть $\rho_1(\cdot, \cdot)$ обозначает старший канонический коэффициент ССА. Тогда

$$\tau^* = \arg \max_{\tau \in \{0, 1, \dots, \tau_{\max}\}} \rho_1(X_{t-\tau}^{\text{obs}}, Y_t^{\text{obs}}). \quad (8)$$

После выбора τ^* далее используются выровненные пары

$$X_t^{\text{obs}} := X^{\text{obs}}(t - \tau^*), \quad Y_t^{\text{obs}} := Y^{\text{obs}}(t).$$

Затем ССА задаёт линейные проекции и декодеры:

$$X_t = D_X^+ X_t^{\text{obs}} \in^k, \quad Y_t = D_Y^+ Y_t^{\text{obs}} \in^k,$$

где $D_X, D_Y \in^{d \times k}$ имеют полный столбцовый ранг. Причинный вывод выполняется в пространстве $(X_t, Y_t) \in^k \times^k$.

5.2 Структурная модель в латентном пространстве

В латентном пространстве фиксируется минимальный граф

$$G_0 = \{Z \rightarrow X, Z \rightarrow Y, X \rightarrow Y\}, \quad X, Y, Z \in^k.$$

Переменная Z описывает общий скрытый фактор, влияющий на оба сигнала, а ребро $X \rightarrow Y$ описывает прямой причинный канал. Модель задаётся линейно-гауссовыми структурными уравнениями

$$\begin{aligned} Z &\sim \pi_\xi(Z), \\ X &= AZ + \varepsilon_x, \quad \varepsilon_x \sim (0, \Sigma_x), \\ Y &= BZ + CX + \varepsilon_y, \quad \varepsilon_y \sim (0, \Sigma_y), \end{aligned} \quad (9)$$

где $A, B, C \in k \times k$ — структурные параметры, а $\Sigma_x, \Sigma_y \succ 0$. Матрица A отвечает за канал $Z \rightarrow X$, матрица B — за канал $Z \rightarrow Y$, матрица C — за прямой канал $X \rightarrow Y$.

Ключевое ограничение модели состоит в том, что структурные параметры $\theta = (A, B, C, \Sigma_x, \Sigma_y)$ являются общими для всех режимов данных. В разных режимах меняется только распределение латента Z . Это соответствует гипотезе инвариантности причинных механизмов: механизм $p(Y | X, Z)$ не должен меняться при изменении распределения причины или скрытого фактора.

5.3 Обучаемый оператор интервенции

Для описания ненаблюдаемых режимов вводится смесевое распределение латента:

$$\pi_\xi(Z) = \sum_{e=1}^{E_{\max}} w_e (Z; \mu_e, \Sigma_e), \quad \sum_{e=1}^{E_{\max}} w_e = 1, \quad w_e \geq 0. \quad (10)$$

Каждая компонента смеси интерпретируется как стохастическая soft-интервенция

$${}_e(Z) \equiv (Z \sim (\mu_e, \Sigma_e)). \quad (11)$$

Такой вид интервенции согласуется с формализмом стохастических интервенций: вместо фиксированной подстановки $Z := z_0$ задаётся новое распределение, из которого генерируется значение Z .

Режим e не наблюдается. Поэтому модель содержит скрытую дискретную переменную

$$e_t \sim (w_1, \dots, w_{E_{\max}}), \quad Z_t | e_t = e \sim (\mu_e, \Sigma_e).$$

Апостериорные вероятности

$$r_{t,e} = p(e_t = e | X_t, Y_t; \theta, \xi)$$

далее используются как soft-сегментация временного ряда на режимы.

5.4 Генеративная модель, правдоподобие и функция потерь

Полная генеративная модель факторизуется в соответствии с графом G_0 :

$$p(X, Y, Z, e | \theta, \xi) = p(e | \xi) p(Z | e; \xi) p(X | Z; \theta) p(Y | X, Z; \theta). \quad (12)$$

Иными словами,

$$p(e \mid \xi) = w_e, \quad p(Z \mid e; \xi) = (Z; \mu_e, \Sigma_e),$$

$$p(X \mid Z; \theta) = (X; AZ, \Sigma_x), \quad p(Y \mid X, Z; \theta) = (Y; BZ + CX, \Sigma_y).$$

Для фиксированного режима e распределение $(X, Y) \mid e$ является гауссовым. Действительно,

$$X = AZ + \varepsilon_x, \quad Y = (B + CA)Z + C\varepsilon_x + \varepsilon_y.$$

Следовательно,

$$(X, Y) \mid e \sim \left(\begin{bmatrix} A\mu_e \\ (B + CA)\mu_e \end{bmatrix}, \begin{bmatrix} A\Sigma_e A^\top + \Sigma_x & A\Sigma_e (B + CA)^\top \\ (B + CA)\Sigma_e A^\top + C\Sigma_x & (B + CA)\Sigma_e (B + CA)^\top \end{bmatrix} \right). \quad (13)$$

Маргинальное правдоподобие наблюдаемой пары имеет вид

$$p(X_t, Y_t \mid \theta, \xi) = \sum_{e=1}^{E_{\max}} w_e p(X_t, Y_t \mid e; \theta, \xi). \quad (14)$$

На структурные параметры ставятся регуляризирующие ARD-приоры:

$$p(A \mid \alpha^A) = \prod_{j=1}^k (A_{\cdot j} \mid 0, (\alpha_j^A)^{-1} I), \quad \alpha_j^A \sim \text{Gamma}(a_0, b_0), \quad (15)$$

аналогично для B и C . Для ковариаций используются обратные распределения Уишарта,

$$\Sigma_x, \Sigma_y \sim (\nu_0, S_0),$$

а для весов смеси используется Dirichlet-приор

$$w \sim (\alpha_w, \dots, \alpha_w), \quad \alpha_w < 1.$$

Малое значение α_w способствует выключению лишних компонент смеси.

Итоговая функция потерь записывается как отрицательное лог-апостериорное правдоподобие:

$$\boxed{(\theta, \xi) = - \sum_{t=1}^T \log \sum_{e=1}^{E_{\max}} w_e p(X_t, Y_t \mid e; \theta) - \log p(\theta) - \log p(w)}. \quad (16)$$

Здесь $p(X_t, Y_t | e; \theta)$ совпадает с интегралом

$$p(X_t, Y_t | e; \theta) = \int p(X_t | Z; \theta) p(Y_t | X_t, Z; \theta) (Z; \mu_e, \Sigma_e) dZ,$$

который в линейно-гауссовом случае вычисляется аналитически и равен компонентному гауссовому распределению из (13).

5.5 ЕМ-обучение causal mixture модели

Оптимизация (16) реализуется ЕМ-алгоритмом. На Е-шаге вычисляются responsibilities:

$$r_{t,e} = \frac{w_e p(X_t, Y_t | e; \theta, \xi)}{\sum_{e'=1}^{E_{\max}} w_{e'} p(X_t, Y_t | e'; \theta, \xi)}. \quad (17)$$

Кроме того, благодаря линейно-гауссовой структуре апостериорное распределение латента имеет замкнутый вид

$$q(Z_t | X_t, Y_t, e) = (\mu_{Z|XY,e}, \Sigma_{Z|XY,e}).$$

На М-шаге максимизируется ожидаемое полное лог-правдоподобие:

$$\theta_{\text{new}} = \arg \max_{\theta} \sum_{t=1}^T \sum_{e=1}^{E_{\max}} r_{t,e} \mathbb{E}_{q(Z_t|X_t,Y_t,e)} [\log p(X_t, Y_t, Z_t | e; \theta)] + \log p(\theta). \quad (18)$$

Параметры смеси обновляются стандартными формулами:

$$w_e^{\text{new}} = \frac{\sum_{t=1}^T r_{t,e} + \alpha_w - 1}{\sum_{e'=1}^{E_{\max}} \sum_{t=1}^T r_{t,e'} + E_{\max}(\alpha_w - 1)}, \quad (19)$$

$$\mu_e^{\text{new}} = \frac{\sum_{t=1}^T r_{t,e} \mathbb{E}[Z_t | X_t, Y_t, e]}{\sum_{t=1}^T r_{t,e}}, \quad (20)$$

$$\Sigma_e^{\text{new}} = \frac{\sum_{t=1}^T r_{t,e} \mathbb{E}[(Z_t - \mu_e^{\text{new}})(Z_t - \mu_e^{\text{new}})^\top | X_t, Y_t, e]}{\sum_{t=1}^T r_{t,e}}. \quad (21)$$

5.6 Восстановление оператора связи и перенос в исходное пространство

Для каждого режима e строится маргинальный оператор связи $X \rightarrow Y$ в латенте. Из структурных уравнений

$$Y = CX + BZ + \varepsilon_y$$

Algorithm 1 EM для Causal Mixture CCA

Input: Данные $= \{(X_t, Y_t)\}_{t=1}^T$, размерность k , верхняя оценка $E_{\max}$, гиперпараметры priоров.

Output: Параметры $\hat{\theta}, \hat{\xi}$, responsibilities $r_{t,e}$, активные режимы.

Инициализировать μ_e с помощью k-means в CCA-латенте, $\Sigma_e = I$,

$w_e = 1/E_{\max}$ **for** $i = 1, \dots, N$ **do**

 Вычислить $r_{t,e}$ по (17) Вычислить $q(Z_t | X_t, Y_t, e)$ аналитически Об-
 новить $\theta = (A, B, C, \Sigma_x, \Sigma_y)$ по (18) Обновить w_e, μ_e, Σ_e по формулам
 М-шага Обновить ARD-гиперпараметры и параметры IW-приоров
 Удалить компоненты с $w_e < \varepsilon_{\text{prune}}$

return $\hat{\theta}, \hat{\xi}, \{r_{t,e}\}$

и формулы для линейной регрессии Z на X внутри режима e получаем

$$\mathbb{E}[Z | X, e] = \mu_e + (Z, X)_e (X, X)^{-1} (X - \mathbb{E}[X | e]).$$

Следовательно, линейная часть зависимости $\mathbb{E}[Y | X, e]$ по X равна

$$F'_e = \hat{C} + \hat{B}_e (Z, X)_e (X, X)^{-1}. \quad (22)$$

Первое слагаемое является прямым каналом $X \rightarrow Y$, второе слагаемое — вкладом общего скрытого фактора Z .

Для интерпретации связей используется SVD-разложение

$$F'_e = U'_e \Lambda'_e V'^{\top}_e, \quad \Lambda'_e = \text{diag}(\lambda'_{e,1}, \dots, \lambda'_{e,k}). \quad (23)$$

Связь между i -й латентной компонентой X и i -й компонентой Y считается активной, если

$$\lambda'_{e,i} > \tau_{\text{thresh}}.$$

Порог τ_{thresh} выбирается по уровню разреженности, индуцированному ARD-приорами.

Перенос в исходное пространство выполняется через CCA-декодеры:

$$A^{\text{obs}} = D_X \hat{A}, \quad B^{\text{obs}} = D_Y \hat{B}, \quad F_e^{\text{obs}} = D_Y F'_e D_X^+. \quad (24)$$

Оператор $F_e^{\text{obs}} \in d \times d$ задаёт режимно-зависимую связь между направлениями исходного сигнала X^{obs} и направлениями исходного сигнала Y^{obs} . Поэтому в исходном пространстве восстановленная причинная связь является не одной стрелкой, а линейным оператором, который можно визуализировать как heatmap или как разреженный граф между координатами сенсоров.

6 Теоретические свойства модели

Ниже формулируются утверждения, необходимые для обоснования предложенного метода. Важно, что идентифицируемость линейно-гауссовой модели с латентными переменными невозможна без дополнительных ограничений: произвольное линейное преобразование латента может порождать ту же наблюдаемую ковариацию. Поэтому в теоремах явно фиксируются условия, которые устраняют эту неоднозначность: ССА-выравнивание латентного пространства, диагональная/ARD-структура, различимость режимов и инвариантность структурных параметров.

Утверждение 6.1 (Универсальность графа G_0 в линейно-гауссовом случае). *Рассмотрим любую линейно-гауссову SCM с конечным числом независимых гауссовых конфаундеров $H_1, \dots, H_m$, одним прямым каналом $X \rightarrow Y$ и уравнениями*

$$H_i \sim (0, \sigma_i^2), \quad X = L_X H + \varepsilon_x, \quad Y = L_Y H + C X + \varepsilon_y,$$

где $H = (H_1, \dots, H_m)^\top$, шумы независимы, $\varepsilon_x \sim (0, \Sigma_x)$, $\varepsilon_y \sim (0, \Sigma_y)$. Тогда эта модель эквивалентна по совместному распределению (X, Y) модели на графе

$$Z \rightarrow X, \quad Z \rightarrow Y, \quad X \rightarrow Y$$

с одним многомерным латентом $Z \in^m$.

Доказательство. Положим $Z = H$. Тогда Z является многомерным гауссовым вектором с диагональной ковариацией

$$\Sigma_Z = \text{diag}(\sigma_1^2, \dots, \sigma_m^2).$$

Исходные структурные уравнения переписываются как

$$Z \sim (0, \Sigma_Z), \quad X = L_X Z + \varepsilon_x, \quad Y = L_Y Z + C X + \varepsilon_y.$$

Это в точности имеет вид (9) при $A = L_X$, $B = L_Y$ и $\pi_\xi(Z) = (0, \Sigma_Z)$. Поскольку преобразование является только переобозначением вектора всех конфаундеров как одного многомерного латента, совместное распределение (X, Y) не меняется. Следовательно, любая такая линейно-гауссова SCM представима на графе G_0 . $\square$

Утверждение 6.2 (Сходимость soft-интервенции к атомарному -оператору). Пусть $\Sigma_e^{(n)} \rightarrow 0$ по спектральной норме, а функция

$$g(z) = p(X_t \mid Z = z; \theta) p(Y_t \mid X_t, Z = z; \theta)$$

непрерывна и ограничена в окрестности μ_e . Тогда

$$\int g(z) (z; \mu_e, \Sigma_e^{(n)}) dz \rightarrow g(\mu_e).$$

Следовательно,

$$(Z \sim (\mu_e, \Sigma_e^{(n)})) \implies (Z = \mu_e),$$

а функция потерь (16) сходится к *marginal likelihood* по семейству атомарных интервенций $\{(Z = \mu_e)\}$.

Доказательство. Последовательность гауссовых мер $(\mu_e, \Sigma_e^{(n)})$ с $\Sigma_e^{(n)} \rightarrow 0$ слабо сходится к дельта-мере δ_{μ_e} . Поэтому для любой непрерывной ограниченной функции g выполнено

$$\int g(z) (z; \mu_e, \Sigma_e^{(n)}) dz \rightarrow \int g(z) \delta_{\mu_e}(dz) = g(\mu_e).$$

В SCM атомарная интервенция $(Z = \mu_e)$ означает замену структурного уравнения для Z на константу $Z := \mu_e$. Поэтому предельное значение интеграла совпадает с правдоподобием при классической интервенции Pearl. Подстановка этого предела в (16) даёт требуемую сходимость функции потерь. $\square$

Теорема 6.3 (Идентифицируемость SCM в латенте при неизвестных режимах). Пусть выполнены следующие условия.

- (C1) Данные порождены линейно-гауссовой моделью (9) со смесью (10).
- (C2) Конечная смесь распределений $(X, Y) \mid e$ является идентифицируемой с точностью до перестановки компонент.
- (C3) Режимы достаточно различимы: семейство параметров $\{(\mu_e, \Sigma_e)\}_{e=1}^{E^*}$ содержит не менее $2k + 1$ линейно независимых наборов первых и вторых моментов.
- (C4) Латентное пространство зафиксировано CCA-нормировкой и ARD-ограничениями так, что допустимые преобразования латента сведены к перестановкам и сменам знака координат.

(C5) Матрицы A и B имеют полный столбцовый ранг, а $\Sigma_x, \Sigma_y \succ 0$.

Тогда глобальный максимум апостериорного правдоподобия, эквивалентный глобальному минимуму (16), восстанавливает структурные параметры (A, B, C) с точностью до перестановки и смены знака латентных компонент и перестановки индексов режимов.

Доказательство. Докажем утверждение по шагам.

Шаг 1: идентифицируемость компонент смеси. По условию (C2) и классическому результату об идентифицируемости конечных смесей гауссовых распределений [8, 2], из маргинального распределения

$$p(X, Y) = \sum_{e=1}^{E^*} w_e p(X, Y \mid e)$$

однозначно восстанавливаются веса w_e , средние m_e^{XY} и ковариации Σ_e^{XY} компонент, с точностью до перестановки индекса e . Тем самым известны все компонентные моменты распределения $(X, Y) \mid e$.

Шаг 2: связь компонентных моментов со структурными параметрами. Для каждого режима e из (13) имеем

$$\begin{aligned} m_e^X &= A\mu_e, & m_e^Y &= (B + CA)\mu_e, \\ \Sigma_e^{XX} &= A\Sigma_e A^\top + \Sigma_x, \\ \Sigma_e^{YX} &= (B + CA)\Sigma_e A^\top + C\Sigma_x. \end{aligned}$$

Значит все наблюдаемые компонентные моменты являются полиномиальными функциями от

$$(A, B, C, \Sigma_x, \Sigma_y, \{\mu_e, \Sigma_e\}_{e=1}^{E^*}).$$

Шаг 3: устранение латентной неоднозначности. В произвольной линейной латентной модели преобразование $Z \mapsto RZ$ может быть компенсировано заменой $A \mapsto AR^{-1}$, $B \mapsto BR^{-1}$, $\mu_e \mapsto R\mu_e$, $\Sigma_e \mapsto R\Sigma_e R^\top$. Поэтому без ограничений параметры не идентифицируемы. Условие (C4) фиксирует ССА-координаты и диагонально-разреженную ARD-структуру. В результате допустимыми остаются только преобразования

$$Z \mapsto PSZ,$$

где P — матрица перестановки, а S — диагональная матрица со значениями ± 1 на диагонали. Это стандартная остаточная неоднозначность латентных моделей.

Шаг 4: использование различимости режимов. Условие (С3) означает, что изменение μ_e и Σ_e создаёт не менее $2k + 1$ независимых вариаций в первых и вторых моментах латента. В линейно-гауссовом случае достаточные статистики латента имеют вид $(Z, ZZ^\top)$; поэтому вариативность режимов является аналогом auxiliary variability в идентифицируемых латентных моделях [5]. Из этой вариативности следует, что две различные тройки структурных параметров (A, B, C) не могут порождать один и тот же набор компонентных моментов для всех режимов, кроме как через остаточное преобразование PS .

Шаг 5: восстановление C . После восстановления латентного представления с точностью до PS структурные уравнения становятся обычной линейной регрессией с наблюдаемыми регрессорами (Z, X) :

$$X = AZ + \varepsilon_x, \quad Y = BZ + CX + \varepsilon_y.$$

Так как по (С5) ковариационная матрица регрессоров невырождена, матрицы A , B и C однозначно задаются нормальными уравнениями популяционной регрессии. Замена Z на PSZ меняет только нумерацию и знаки столбцов A, B и соответствующих компонент режима, но не меняет наблюдаемую SCM.

Следовательно, глобальный максимум правдоподобия восстанавливает (A, B, C) с точностью до перестановки и смены знака латентных компонент, а также перестановки режимов. Теорема доказана. $\square$

Теорема 6.4 (Корректность переноса SCM в исходное пространство). Пусть $D_X, D_Y \in \mathbb{R}^{d \times k}$ имеют полный столбцовый ранг, а наблюдаемые переменные являются линейными образами латентных:

$$X^{\text{obs}} = D_X X, \quad Y^{\text{obs}} = D_Y Y.$$

Пусть в латентном пространстве задана SCM (9). Тогда индуцированная SCM в исходном пространстве с параметрами

$$A^{\text{obs}} = D_X A, \quad B^{\text{obs}} = D_Y B, \quad F_e^{\text{obs}} = D_Y F_e' D_X^+$$

является каузально согласованной с латентной SCM. В частности, для $x^{\text{obs}} \in \text{Im } D_X$ выполнено

$$p^{\text{obs}}(Y^{\text{obs}} \mid (X^{\text{obs}} = x^{\text{obs}})) = (D_Y)_\# p^{\text{latent}}(Y \mid (X = D_X^+ x^{\text{obs}})), \quad (25)$$

где $(D_Y)_\#$ обозначает push-forward распределения линейным отображением D_Y .

Доказательство. Так как D_X имеет полный столбцовый ранг, для любого $x^{\text{obs}} \in \text{Im } D_X$ существует единственный латентный вектор

$$x = D_X^+ x^{\text{obs}}$$

такой, что $D_X x = x^{\text{obs}}$. Интервенция ($X^{\text{obs}} = x^{\text{obs}}$) в индуцированной модели заменяет структурное уравнение для наблюдаемой переменной X^{obs} на константу. Поскольку $X^{\text{obs}} = D_X X$ является детерминированным линейным образом X , эта интервенция эквивалентна интервенции ($X = x$) в латентной модели, если $x^{\text{obs}} \in \text{Im } D_X$.

В латентной SCM после интервенции ($X = x$) остаётся уравнение

$$Y = BZ + Cx + \varepsilon_y.$$

Наблюдаемая переменная равна

$$Y^{\text{obs}} = D_Y Y = D_Y BZ + D_Y Cx + D_Y \varepsilon_y.$$

Следовательно, распределение Y^{obs} получается из распределения Y после латентной интервенции линейным отображением D_Y . Это и есть равенство push-forward распределений (25). Такой тип согласованности соответствует общей идее каузальной согласованности структурных моделей при детерминированных отображениях переменных [9]. $\square$

Если декодер содержит дополнительный шум, то равенство (25) заменяется свёрткой push-forward распределения с шумом декодера. В экспериментальной части используется линейный ССА-декодер без явного стохастического декодерного шума, поэтому применяется именно формула (25).

7 Экспериментальная проверка

Экспериментальная часть предназначена для проверки двух утверждений: во-первых, ССА-сжатие действительно выделяет низкоразмерное пространство, в котором улучшается предсказание одного сигнала по другому; во-вторых, добавление режимной causal mixture модели позволяет получить более интерпретируемую структуру связей, чем единая модель без режимов.

7.1 Данные

В качестве основного набора данных используются парные многомерные временные ряды, записанные с двух устройств. Один сигнал X^{obs} соответствует движению первого устройства, второй сигнал Y^{obs} — движению второго устройства. Для каждого устройства доступны следующие группы признаков:

- акселерометр: координаты x, y, z ;
- гироскоп: координаты x, y, z ;
- ориентация: yaw, pitch, roll и кватернионные компоненты.

Таким образом, в каждый момент времени наблюдается многомерный вектор признаков. Сырые ряды имеют разные частоты дискретизации, поэтому перед обучением они синхронизируются по времени.

Предобработка. Предобработка состоит из следующих шагов:

1. приведение временных меток обоих устройств к общей шкале;
2. интерполяция сигналов на общую равномерную сетку;
3. удаление коротких участков с пропусками или сильными артефактами;
4. стандартизация каждого признака по обучающей части;
5. выбор лага τ^* по формуле (8);
6. формирование пар $(X_{t-\tau^*}^{\text{obs}}, Y_t^{\text{obs}})$.

7.2 Модели и базовые сравнения

Сравниваются следующие модели:

1. **Raw Ridge**: ridge-регрессия из исходного пространства X^{obs} в Y^{obs} без ССА-сжатия.
2. **ССА latent Ridge**: ССА-сжатие до размерности k и ridge-регрессия в латентном пространстве.




Рис. 1: Пример синхронизированных временных рядов после предобработки. На рисунке должны быть показаны основные координаты сенсоров для двух устройств.

3. **3CA**: предложенная модель, включающая выбор лага, ССА-сжатие и causal mixture слой в латентном пространстве.
4. **Ablation** $E = 1$: та же модель, но с одним режимом. Это проверяет, даёт ли пользу именно режимная структура.

Основной гиперпараметр — латентная размерность k . В экспериментах перебираются значения

$$k \in \{1, 2, \dots, 12\}.$$

Для mixture-модели задаётся верхняя оценка $E_{\max}$, после чего лишние компоненты удаляются по малому весу w_e .

7.3 Метрики качества

Основная предсказательная метрика — коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_t \|Y_t - \hat{Y}_t\|_2^2}{\sum_t \|Y_t - \bar{Y}\|_2^2}.$$

Чем больше R^2 , тем лучше модель предсказывает целевой сигнал. Дополнительно используются:

- MSE предсказания Y по X ;
- стабильность найденных режимов при разных инициализациях ЕМ;
- разреженность оператора F'_e или F_e^{obs} ;
- визуальная интерпретируемость сегментации по responsibilities $r_{t,e}$;
- для дальнейшего развития метода — cross-map skill внутри найденных режимов.

7.4 Результаты: качество предсказания

Первый эксперимент проверяет зависимость качества предсказания от латентной размерности k . Для каждого k обучаются модели Raw Ridge, ССА latent Ridge и ЗСА. Ожидаемая картина состоит в том, что при слишком малом k ССА-латент теряет существенную часть информации, а при увеличении k качество растёт и затем выходит на насыщение.




Рис. 2: Зависимость R^2 от латентной размерности k для первого режима. Синяя линия соответствует ЗСА, оранжевая — ССА latent Ridge, зелёная пунктирная линия — Raw Ridge.

По графику 2 сравнивается не только абсолютное качество, но и сложность модели. Если ЗСА достигает лучшего R^2 при умеренном k ,

это подтверждает, что причинно-режимный слой использует латентное пространство эффективнее, чем простая регрессия после ССА.

7.5 Результаты: найденные режимы

Следующий эксперимент анализирует responsibilities $r_{t,e}$, полученные на Е-шаге ЕМ-алгоритма. Они задают soft-разбиение временного ряда на режимы. В контексте движения эти режимы могут соответствовать различным фазам: активному движению, слабому движению, переходному участку или участку покоя.




Рис. 3: Сегментация временного ряда на режимы по responsibilities $r_{t,e}$. Цветом должны быть отмечены найденные режимы или вероятности принадлежности к ним.

Интерпретируемость модели проверяется тем, насколько найденные режимы согласуются с визуально различимыми фазами сигнала и насколько устойчиво они воспроизводятся при разных инициализациях ЕМ.

7.6 Результаты: структура связей и предсказание

После обучения для каждого режима вычисляется оператор F'_e по формуле (22) и его перенос F_e^{obs} по формуле (24). Эти операторы можно визуализировать как heatmap или как граф связей между координатами сенсоров. Ненулевые сингулярные значения в (23) соответствуют активным каналам связи.

Для проверки того, что найденная структура не является только формальной, дополнительно строится график предсказания Y по X . На нём сравниваются истинный сигнал и предсказание модели.




Рис. 4: Пример восстановленной структуры 3CA: heatmap оператора связи или граф активных латентных каналов.




Рис. 5: Сравнение истинного целевого сигнала и предсказания модели. Рисунок используется для визуальной проверки качества восстановления динамики.

7.7 План эксперимента для текстовых данных

Дополнительно метод может быть проверен на парных текстовых данных. В этом случае X^{obs} и Y^{obs} являются эмбедами связанных документов или фрагментов текста. Латент Z интерпретируется как общий семантический фактор, а интервенция ($Z \sim (\mu_e, \Sigma_e)$) соответствует изменению скрытого семантического режима.

Для текстового эксперимента предполагается следующий протокол:

1. построить эмбединги документов с помощью фиксированной языковой модели;

2. сформировать пары связанных текстов $(X^{\text{obs}}, Y^{\text{obs}})$;
3. выполнить ССА-сжатие до размерности k ;
4. обучить causal mixture модель;
5. сравнить качество предсказания эмбединга Y по X с baseline-моделями;
6. проанализировать найденные режимы как тематические или стилиевые кластеры.

7.8 Выводы по экспериментальной части

Эксперименты должны подтвердить три основных свойства метода. Во-первых, ССА-сжатие позволяет перейти от высокоразмерных временных рядов к компактному латентному пространству без существенной потери предсказательного сигнала. Во-вторых, causal mixture слой выделяет режимы, которые имеют содержательную интерпретацию во времени. В-третьих, перенос оператора связи F'_e в исходное пространство даёт визуализируемую структуру связей между координатами исходных сенсоров.

Основной итог экспериментальной проверки формулируется следующим образом: предложенный метод должен не только улучшать или сохранять качество предсказания относительно ССА latent Ridge, но и давать дополнительный объект интерпретации — режимно-зависимый причинный оператор F_e^{obs} .

Список литературы

- [1] Klami A., Virtanen S., Kaski S. Bayesian Canonical Correlation Analysis. *Journal of Machine Learning Research*, 14:965–1003, 2013.
- [2] McLachlan G., Peel D. *Finite Mixture Models*. Wiley, 2000.
- [3] Dempster A. P., Laird N. M., Rubin D. B. Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society B*, 39(1):1–38, 1977.
- [4] Correa J., Bareinboim E. A Calculus for Stochastic Interventions: Causal Effect Identification and Surrogate Experiments. *AAAI*, 2020.

- [5] Khemakhem I., Kingma D., Monti R., Hyvärinen A. Variational Autoencoders and Nonlinear ICA: A Unifying Framework. *AISTATS*, 2020.
- [6] Schölkopf B., Locatello F., Bauer S., Ke N. R., Kalchbrenner N., Goyal A., Bengio Y. Toward Causal Representation Learning. *Proceedings of the IEEE*, 109(5):612–634, 2021.
- [7] Beal M. J. *Variational Algorithms for Approximate Bayesian Inference*. PhD thesis, University College London, 2003.
- [8] Teicher H. Identifiability of finite mixtures. *Annals of Mathematical Statistics*, 34:1265–1269, 1963.
- [9] Rubenstein P., Weichwald S., Bongers S., Mooij J., Janzing D., Grosse-Wentrup M., Schölkopf B. Causal Consistency of Structural Equation Models. *UAI*, 2017.
- [10] Pearl J. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, 2nd edition, 2009.
- [11] Sugihara G., May R., Ye H., Hsieh C., Deyle E., Fogarty M., Munch S. Detecting Causality in Complex Ecosystems. *Science*, 338(6106):496–500, 2012.