

Вероятностные модели причинно-следственных связей в сходящихся отображениях

Иконников Марк

май 2026


Проблема

Даны два высокоразмерных временных ряда

$$\mathcal{D} = \{(X^{\text{obs}}(t), Y^{\text{obs}}(t))\}_{t=1}^T, \quad X^{\text{obs}}(t), Y^{\text{obs}}(t) \in \mathbb{R}^d, \quad d \gg 1.$$

Требуется восстановить интерпретируемую причинную структуру между сигналами, имея только наблюдательные данные.

3D phase trajectory: first validation regime [5, 6] sec



Цель работы

Основная цель

Построить структурную причинную модель, которая по наблюдательным данным выделяет скрытые режимы и поддерживает интервенционные запросы.

Идея

Мы не восстанавливаем граф напрямую в исходном пространстве $\mathbb{R}^d$. Сначала переходим в CCA-латент, строим там SCM, а затем переносим найденные связи обратно.




Рис.: Classic CCA

Ключевая идея подхода

Latent SCM


Работаем с минимальным графом

$$Z \rightarrow X, \quad Z \rightarrow Y, \quad X \rightarrow Y.$$

Скрытый Z отвечает за общий фактор, а канал $X \rightarrow Y$ — за прямое влияние между сигналами.

Обучаемая интервенция

Оператор $\text{do}(Z = z_0)$ заменяется обучаемой стохастической политикой-смесью. Компоненты смеси соответствуют ненаблюдаемым режимам данных.



Observed $X, Y \rightarrow$ CCA
latent $\rightarrow$ SCM $\rightarrow$ graph

Структурная модель в латенте

Фиксируем линейно-гауссову SCM:

$$Z \sim \pi_{\xi}(Z),$$

$$X = AZ + \varepsilon_x, \quad \varepsilon_x \sim \mathcal{N}(0, \Sigma_x),$$

$$Y = BZ + CX + \varepsilon_y, \quad \varepsilon_y \sim \mathcal{N}(0, \Sigma_y).$$

Смысл параметров

A описывает канал $Z \rightarrow X$, B — канал $Z \rightarrow Y$, а C — прямой канал $X \rightarrow Y$. Все три матрицы являются общими для всех режимов.

Каузальная интерпретация

Модель явно разделяет общий источник зависимости и прямое влияние, поэтому интервенция на Z или X имеет смысл внутри заданной SCM.

Обучаемый do-оператор

Задаем распределение интервенций как смесь гауссиан:

$$\pi_{\xi}(Z) = \sum_{e=1}^{E_{\max}} w_e \mathcal{N}(Z; \mu_e, \Sigma_e), \quad \sum_e w_e = 1, \quad w_e \geq 0.$$

Каждая компонента задает soft-интервенцию

$$\text{do}_e(Z) \equiv \text{do}(Z \sim \mathcal{N}(\mu_e, \Sigma_e)).$$

Предельный случай

При $\Sigma_e \rightarrow 0$ компонента смеси вырождается в атомарную интервенцию $\text{do}(Z = \mu_e)$.

3CA Algorithm

1. **Выбор лага:** ищем τ^* через максимум старшего ССА-коэффициента.
2. **ССА-сжатие:** переходим от $\mathbb{R}^d$ к $\mathbb{R}^k$.
3. **Causal Mixture Model:** обучаем SCM с общими параметрами $\theta = (A, B, C)$ и смесью режимов.
4. **ЕМ-обучение:** выводим responsibilities $r_{t,e}$ и параметры режимов.
5. **Извлечение графа:** получаем per-regime оператор F'_e и переносим его в исходное пространство.

Генеративная модель, loss и EM

Causal mixture

$$p(X, Y, Z, e \mid \theta, \xi) = p(e \mid \xi)p(Z \mid e; \xi)p(X \mid Z; \theta)p(Y \mid X, Z; \theta).$$

$$p(X_t, Y_t \mid \theta, \xi) = \sum_{e=1}^{E_{\max}} w_e \int p(X_t \mid Z; \theta)p(Y_t \mid X_t, Z; \theta)\mathcal{N}(Z; \mu_e, \Sigma_e)dZ.$$

Полученный $\mathcal{L}$

$$\mathcal{L}(\theta, \xi) = - \sum_{t=1}^T \log \sum_{e=1}^{E_{\max}} w_e p(X_t, Y_t \mid \text{do}_e; \theta) - \log p(\theta) - \log p(w).$$

ЕМ-обучение

$$r_{t,e} = \frac{w_e p(X_t, Y_t \mid e; \theta, \xi)}{\sum_{e'} w_{e'} p(X_t, Y_t \mid e'; \theta, \xi)}.$$

Извлечение каузального графа

После обучения для каждого режима строим оператор связи $X \rightarrow Y$ в латенте:

$$F'_e = \hat{C} + \hat{B} \text{Cov}_e(Z, X) \text{Cov}_e(X, X)^{-1}.$$

Далее используем SVD-разложение

$$F'_e = U'_e \Lambda'_e V'^{\top}_e, \quad \Lambda'_e = \text{diag}(\lambda'_{e,1}, \dots, \lambda'_{e,k}).$$

Восстановление графа

ССА дает линейные декодеры D_X, D_Y . Через них переносим найденные структурные параметры:

$$A^{\text{obs}} = D_X \hat{A}, \quad B^{\text{obs}} = D_Y \hat{B}.$$

Оператор связи в исходных координатах:

$$F_e^{\text{obs}} = D_Y F'_e D_X^+.$$

Теоретические утверждения

Утверждение 1: идентифицируемость SCM в латенте

Пусть SCM линейно-гауссова, истинное число режимов ограничено, а моменты компонент смеси различимы.

Тогда глобальный максимум $\mathcal{L}$ восстанавливает структурные параметры (A, B, C) с точностью до перестановки и смены знака латентных компонент.

Теорема 2: корректность переноса SCM в исходное пространство

Пусть $\text{SCM}_{\text{latent}}$ — обученная SCM с параметрами $(\hat{A}, \hat{B}, \hat{C})$ в латенте, а D_X, D_Y — CCA-декодеры. Тогда индуцированная SCM в $\mathbb{R}^d$ с

$$A^{\text{obs}} = D_X \hat{A}, \quad B^{\text{obs}} = D_Y \hat{B}, \quad F_e^{\text{obs}} = D_Y F_e' D_X^+$$

сохраняет интервенционную семантику:

$$p^{\text{obs}}(Y^{\text{obs}} \mid \text{do}(X^{\text{obs}})) = p^{\text{latent}}(Y \mid \text{do}(X)) \Big|_{X=D_X^+ X^{\text{obs}}, Y=D_Y^+ Y^{\text{obs}}}.$$

Связь с ССМ

Классический ССМ

ССМ проверяет, можно ли по shadow manifold одного ряда восстановить состояние другого. Рост качества cross-mapping при увеличении длины библиотеки интерпретируется как признак причинной связи.

Наша модификация

Мы добавляем к ССМ латентную интервенционную модель. ССА выделяет совместный низкоразмерный сигнал, mixture-модель разделяет режимы, а per-regime операторы F'_e дают слой, внутри которого можно применять ССМ или сравнивать causal strength.

Метрики качества

Метрика	Что измеряет
Predictive error	Насколько хорошо модель предсказывает Y_t по $X_{t-\tau}$
Cross-map skill	Растет ли качество CCM при увеличении library length
Regime stability	Устойчивы ли найденные режимы при разных инициализациях EM
Graph sparsity	Получается ли разреженный и интерпретируемый оператор F'_e
Intervention consistency	Согласованы ли ответы модели на $\text{do}_e(Z)$ между режимами

Базовые сравнения

Сравниваем с CCA без каузального слоя, с единственным режимом $E = 1$, и с обычным CCM без латентного разделения режимов.

Экспериментальный сетап

Данные

Парные многомерные временные ряды с датчиков движения: акселерометр, гироскоп и ориентация.








Рис.: Временные ряды

Результаты



Результаты: модель и предсказание



Тезисы, выносимые на защиту

1. **Вид do-интервенции.** Оператор $\text{do}(Z = z_0)$ формализуется как обучаемая стохастическая смесь

$$\pi_{\xi}(Z) = \sum_e w_e \mathcal{N}(Z; \mu_e, \Sigma_e),$$

где компоненты соответствуют скрытым режимам данных.

2. **Алгоритм.** Предложен ЗСА-пайплайн: выбор лага, ССА-сжатие, causal mixture SCM, ЕМ-обучение, извлечение и перенос графа.
3. **Теорема об идентифицируемости.** При различных режимах и инвариантных (A, B, C) структурные параметры восстанавливаются в латенте с точностью до стандартных неоднозначностей.
4. **Теорема о переносе.** ССА-декодеры индуцируют SCM в исходном пространстве и сохраняют интервенционную семантику.

Литература

Авторы	Год	Публикация
Klami, Virtanen, Kaski	2013	Journal of Machine Learning Research, 14:965–1003
McLachlan, Peel	2000	Wiley
Dempster, Laird, Rubin	1977	Journal of the Royal Statistical Society B, 39(1):1–38
Correa, Bareinboim	2020	AAAI
Khemakhem, Kingma, Monti, Hyvärinen	2020	AISTATS
Schölkopf et al.	2021	Proceedings of the IEEE, 109(5):612–634
Beal	2003	PhD thesis, University College London
Teicher	1963	Annals of Mathematical Statistics, 34:1265–1269
Rubenstein et al.	2017	UAI
Pearl	2009	Cambridge University Press, 2nd edition
Sugihara et al.	2012	Science, 338(6106):496–500