

Вероятностные модели причинно-следственных связей в сходящихся отображениях

Иконников Марк Игоревич
д.ф-м.н. Стрижов В.В.


июнь 2026

Восстановление графа причинности

Даны синхронные наблюдаемые временные ряды

$$\mathcal{D} = \{(X_t^{\text{obs}}, Y_t^{\text{obs}})\}_{t=1}^T, \quad X_t^{\text{obs}} \in \mathbb{R}^{d_x}, \quad Y_t^{\text{obs}} \in \mathbb{R}^{d_y}.$$

Требуется восстановить причинную структуру между источником X^{obs} и приёмником Y^{obs} при наличии скрытых режимов движения, с использованием скрытого состояния.



Трёхдольный граф

Линейно-гауссова модель

$$z_t \mid e_t = e \sim \mathcal{N}(\mu_e, \Sigma_e),$$


$$x_t \mid z_t \sim \mathcal{N}(W_X z_t, (\beta_X)^{-1} I_p),$$

$$y_t \mid z_t \sim \mathcal{N}(W_Y z_t, (\beta_Y)^{-1} I_q).$$

Смысл слоёв

$$e \rightarrow Z, \quad Z \rightarrow X, \quad Z \rightarrow Y.$$

e : режим движения,
 Z : скрытая причина.



Корректность интервенции

Корректность интервенции (Иконников, 2026)

Пусть задана линейно-гауссова SCM с DAG

$$e \rightarrow Z, \quad Z \rightarrow \tilde{X}, \quad Z \rightarrow \tilde{Y},$$

где $Z = (Z_1, \dots, Z_d)$. Тогда постинтервенционное распределение после вмешательства $\text{do}(Z_k = z^*)$ имеет вид

$$p(\tilde{x}, \tilde{y} \mid \text{do}(Z_k = z^*)) = \int p(\tilde{x} \mid Z_k = z^*, z_{-k}) p(\tilde{y} \mid Z_k = z^*, z_{-k}) p(z_{-k}) dz_{-k}.$$

При диагональных Σ_e

$$p(z_{-k}) = \sum_{e=1}^E \pi_e \prod_{l \neq k} \mathcal{N}(z_l \mid (\mu_e)_l, (\Sigma_e)_{ll}).$$

Отличие от обусловливания:

$$p(z_{-k} \mid \text{do}(Z_k = z^*)) = p(z_{-k}),$$

но в общем случае

$$p(z_{-k} \mid Z_k = z^*) \neq p(z_{-k}),$$

так как при наблюдении остаётся путь

Режимы как источник идентифицируемости

Режим e_t — скрытая метка участка времени:

$$e_t \in \{1, \dots, E\}.$$

Он меняет только распределение латента:

$$z_t \mid e_t = e \sim \mathcal{N}(\mu_e, \Sigma_e),$$

но не меняет механизмы наблюдений:

$$W_X, W_Y = \text{const.}$$

Смысл

Режимы задают разные среды, в которых дисперсии латентных координат меняются неодинаково. Это разрушает вращательную неоднозначность ССА и делает координаты Z_k интерпретируемыми.



Идентифицируемость графа через режимы

Теорема 1


Пусть

$$Z \mid e \sim \mathcal{N}(\mu_e, \Sigma_e), \quad \Sigma_e = \text{diag}(\sigma_{e,1}^2, \dots, \sigma_{e,d}^2),$$

$$\forall k \neq l \exists e, e' : \frac{\sigma_{e',k}^2}{\sigma_{e,k}^2} \neq \frac{\sigma_{e',l}^2}{\sigma_{e,l}^2}, \quad \text{rank} \begin{pmatrix} W_X \\ W_Y \end{pmatrix} = d.$$

Тогда

W_X, W_Y восстанавливаемы из $p(X, Y)$ с точностью до $Z_k \mapsto \pm Z_{\pi(k)}$.



IE-критерий в линейной модели

В линейной модели:

$$\tilde{X}_i = \sum_{l=1}^d W_{il}^X Z_l + \varepsilon_i.$$

После интервенции $\text{do}(Z_k = z^*)$:

$$\mathbb{E}[\tilde{X}_i \mid \text{do}(Z_k = z^*)] = W_{ik}^X z^* + \sum_{l \neq k} W_{il}^X \bar{\mu}_l.$$

Следовательно,

$$\text{IE}_{ik}^X = \text{Var}_{z^* \sim p(Z_k)} \left[W_{ik}^X z^* + \sum_{l \neq k} W_{il}^X \bar{\mu}_l \right],$$

$$\text{IE}_{ik}^X = (W_{ik}^X)^2 \bar{v}_k.$$

Критерий ребра

$$Z_k \rightarrow \tilde{X}_i \iff \text{IE}_{ik}^X > \theta_X.$$

Теорема 2: состоятельность IE-критерия

Пусть данные сгенерированы истинной SCM с матрицей грузов W_X^* . Пусть выполнены условия идентифицируемости теоремы 1, и оценки ЕМ являются состоятельными:

$$\widehat{W}_X \xrightarrow{P} W_X^*, \quad \widehat{v}_k \xrightarrow{P} \bar{v}_k^*.$$

Тогда

$$\widehat{IE}_{ik}^X = (\widehat{W}_{ik}^X)^2 \widehat{v}_k \xrightarrow{P} IE_{ik}^{X*} = (W_{ik}^{X*})^2 \bar{v}_k^*.$$

Следовательно,

$$W_{ik}^{X*} = 0 \implies \widehat{IE}_{ik}^X \xrightarrow{P} 0,$$

а если

$$W_{ik}^{X*} \neq 0, \quad \bar{v}_k^* > 0,$$

то

$$\widehat{IE}_{ik}^X \xrightarrow{P} (W_{ik}^{X*})^2 \bar{v}_k^* > 0.$$

ЕМ-алгоритм

Шаг 0. Препроцессинг

$$\tau^* = \arg \max \text{CCA}_1(x_t, y_{t-\tau}), \quad \tilde{x}_t, \tilde{y}_t \leftarrow \text{Hankel}(x, y; L, \tau^*)$$

Шаг 1. Инициализация

$$W_X^{(0)}, W_Y^{(0)} \leftarrow \text{CCA}; \quad e_t^{(0)} \leftarrow \text{KMeans}(\hat{z}_t)$$

В цикле: Шаг 2. Е-шаг

$$q(z_t \mid e, \tilde{x}_t, \tilde{y}_t) = \mathcal{N}(m_t^{(e)}, V_t^{(e)}); \quad \gamma_t^{(e)} = p(e_t = e \mid \tilde{x}_t, \tilde{y}_t)$$

Интерпретация: оцениваем латент при каждом режиме и вероятность самого режима

Шаг 3. DO-шаг

$$\bar{v}_k = \text{Var}_{p(Z_k)}[Z_k], \quad \text{IE}_{ik}^X = (W_{ik}^X)^2 \bar{v}_k$$

Интерпретация: считаем интервенционный эффект — дисперсию отклика $\tilde{X}_i$ на $do(Z_k)$

Шаг 4. М-шаг

$$W_X, W_Y, \beta, \mu_e, \Sigma_e, \pi \leftarrow \arg \max Q; \quad \alpha_{ik}^X = 1/\text{IE}_{ik}^X$$

Интерпретация: обновляем параметры по замкнутым формулам; ARD-precision

Байесовский вывод в E-шаге

Апостериорное распределение латента при режиме e :

$$q(z_t \mid e_t = e, \tilde{x}_t, \tilde{y}_t) = \mathcal{N}(m_t^{(e)}, V_t^{(e)})$$

Точность (precision matrix):

$$(V_t^{(e)})^{-1} = \underbrace{\Sigma_e^{-1}}_{\text{приор режима}} + \underbrace{\beta_X W_X^\top W_X}_{\text{вклад } \tilde{x}_t} + \underbrace{\beta_Y W_Y^\top W_Y}_{\text{вклад } \tilde{y}_t}$$

Среднее:

$$m_t^{(e)} = V_t^{(e)} [\Sigma_e^{-1} \mu_e + \beta_X W_X^\top \tilde{x}_t + \beta_Y W_Y^\top \tilde{y}_t]$$

Интерпретация: апостериор сочетает три источника информации — priorное распределение латента в режиме e и наблюдения из двух потоков, взвешенные их точностями

Маргинальные моменты для M-шага

$$\hat{m}_t = \sum_e \gamma_t^{(e)} m_t^{(e)}, \quad \hat{S}_t = \sum_e \gamma_t^{(e)} \left(V_t^{(e)} + m_t^{(e)} (m_t^{(e)})^\top \right)$$

Интерпретация: усредняем по всем режимам с весами $\gamma_t^{(e)}$ — получаем ожидания, нужные для обновления W, β, Σ_e

Восстановление разреженного графа

На элементы матриц загрузок вводится ARD-приор:

$$W_{ik}^X \mid \alpha_{ik}^X \sim \mathcal{N}(0, (\alpha_{ik}^X)^{-1}), \quad W_{jk}^Y \mid \alpha_{jk}^Y \sim \mathcal{N}(0, (\alpha_{jk}^Y)^{-1}).$$

Обновление загрузок имеет вид weighted ridge-регрессии:

$$W_X^{new} = \arg \min_W \sum_t \mathbb{E}_q \|\tilde{x}_t - W z_t\|^2 + \sum_{i,k} \alpha_{ik}^X W_{ik}^2.$$

$$\alpha_{ik} \uparrow \Rightarrow W_{ik} \rightarrow 0 \Rightarrow \mathbb{E}_{ik} \rightarrow 0.$$

Итоговый критерий

Граф извлекается не по весам W , а по интервенционным эффектам $\mathbb{E}$.


Вычислительный эксперимент

Данные

Два смартфона: рука и пояс. Используются акселерометр и гироскоп.


Проверка

Синтетический эксперимент с известным графом и эксперимент на реальных сенсорных данных.




Синтетический эксперимент


Метод	Mean F1	Mean ROC AUC
Ours: DO-ARD CausalBCCA	0.9333	0.9801
Sparse PCA on $[X, Y]$	0.7333	0.8299
ICA on $[X, Y]$	0.6800	0.8914
PCA on $[X, Y]$	0.6400	0.8280
Classical CCA loadings	0.6333	0.8198




Сравнение методов



Истинный граф



Восстановленный граф



Complexity k	AR(Y) only	CCA embedding	BCCA no regime	Causal BCCA full
0	0.333	—	—	—
2	—	0.336	0.346	0.347
4	—	0.339	0.362	0.363
6	—	0.356	0.361	0.361
8	—	0.360	0.360	0.362
10	—	0.364	0.366	0.367
12	—	0.365	0.369	0.368

Таблица: Mean test R^2 over target channels, forecast horizon $h = 12h$.

Тезисы, выносимые на защиту

1. Предложена латентная SCM с режимной структурой:

$$e \rightarrow Z, \quad Z \rightarrow \tilde{X}, \quad Z \rightarrow \tilde{Y}.$$

2. Формализована интервенция $\text{do}(Z_k = z^*)$ на латентные компоненты в смысле do-исчисления Пёрла.
3. Введён интервенционный критерий выделения каузальных рёбер:

$$\text{IE}_{ik}^X = (W_{ik}^X)^2 \bar{v}_k.$$

4. **Доказана идентифицируемость** каузального графа при условии различимости режимных дисперсий (Теорема 1).
5. **Доказана состоятельность** IE-критерия: $\text{IE}_{ik}^X \xrightarrow{P} 0$ при отсутствии ребра и $\text{IE}_{ik}^X \xrightarrow{P} \text{const} > 0$ при его наличии (Теорема 2).
6. Построен EM-алгоритм с замкнутыми формулами M-шага (Теорема 3), совместно оценивающий режимы, латент, параметры и каузальный граф.